# 2026-03-04 每日论文分析

## 标签汇总

## [Meta], [腾讯], [阿里], [上海交大], [顶级学者], [RL演进], [多模态], [代码/Agent], [推理/CoT], [强推], [有趣但有缺陷], [范式转变]

## 1. Beyond Language Modeling: An Exploration of Multimodal Pretraining

**标题：** 超越语言建模：多模态预训练探索 **作者：** Shengbang Tong, David Fan, John Nguyen, Ellis Brown, Yann LeCun 等 **ArXiv ID：** 2603.03276 **机构：** Meta AI ### 动机 当前多模态基础模型的设计空间高度不透明，绝大多数工作基于已有的语言模型进行多模态对齐，无法隔离多模态预训练本身的核心影响因子。本文解决的核心问题是：如何从零开始设计原生多模态预训练框架，量化不同组件对多模态能力的贡献。 形式化描述：设多模态模型的能力函数为 \(F(\mathcal{M}, \mathcal{D}, \mathcal{A}, \mathcal{S})\)，其中 \(\mathcal{M}\) 为模型架构，\(\mathcal{D}\) 为多模态数据集，\(\mathcal{A}\) 为训练目标，\(\mathcal{S}\) 为训练策略。现有研究无法分解各因子的边际贡献，因为初始的语言模型权重引入了混淆变量。本文通过受控实验消除语言模型初始化的干扰，直接估计各因子的偏导数 \(\partial F/\partial \mathcal{M}, \partial F/\partial \mathcal{D}, \partial F/\partial \mathcal{A}, \partial F/\partial \mathcal{S}\)。 ### 核心公式与设计 本文采用 Transfusion 框架，核心训练目标为： \[\mathcal{L} = \lambda_1 \mathcal{L}_{\text{NLL}}(x_{\text{text}}) + \lambda_2 \mathcal{L}_{\text{diffusion}}(x_{\text{vision}}) + \lambda_3 \mathcal{L}_{\text{alignment}}(x_{\text{text}}, x_{\text{vision}})\] - \(\mathcal{L}_{\text{NLL}}\)：文本的下一词预测损失，标准自回归语言建模目标 - \(\mathcal{L}_{\text{diffusion}}\)：视觉数据的扩散损失，用于图像/视频生成 - \(\mathcal{L}_{\text{alignment}}\)：跨模态对齐损失，确保文本和视觉表征在共享空间中一致 - \(\lambda_1, \lambda_2, \lambda_3\)：损失权重，本文通过 ablation 确定最优比例为 5:3:2 ### 核心假设 1. **显式假设1**：存在统一的视觉表征可以同时支持视觉理解和生成任务，无需独立的编码器和解码器 2. **显式假设2**：多模态数据之间存在互补性，联合训练可以提升单模态下游任务性能 3. **隐式假设1**：Transfusion 架构的混合建模（自回归+扩散）可以统一处理离散文本和连续视觉信号 4.

**隐式假设2**：IsoFLOP 控制下的 scaling law 可以准确反映模型的真实 scaling 特性，不受训练时长干扰 有效性评估：假设1通过 RAE 表征的实验验证成立，在理解和生成任务上均超过独立架构；假设2通过单模态任务在多模态训练后性能提升验证成立；隐式假设1在实验中表现良好，但未在极端规模下验证；隐式假设2的 IsoFLOP 控制存在近似误差，可能影响 scaling 系数的精确性。 ### 技术贡献 1. 首次通过无语言模型初始化的受控实验，系统梳理了多模态预训练的设计空间，得到4条核心经验结论 2. 提出 Representation Autoencoder (RAE) 作为统一视觉表征，同时超越了纯理解和纯生成的专用架构 3. 发现多模态预训练的 scaling 不对称性：视觉任务的样本复杂度是语言任务的3.7倍，验证了视觉任务更数据 hungry 的经验观察 4. 证明 MoE 架构可以天然解决 scaling 不对称问题，专家会自发出现模态 specialization，语言相关专家激活率在文本任务中提升42%，视觉相关专家激活率在视觉任务中提升57% 5. 首次验证了通用多模态预训练可以自发涌现世界建模能力，在无显式训练的情况下完成基本的物理常识推理任务 与 prior work 的关系：区别于 Flamingo、GPT-4V 等基于语言模型对齐的多模态方案，本文从零开始训练原生多模态模型，避免了语言模型的偏置；扩展了 Transfusion 框架的适用范围，首次验证其在多任务多模态场景下的有效性。 ### 实验设计 #### 基线方法 - 纯语言 Transformer 基线：仅在文本数据上训练的标准 LLaMA 架构 - 纯视觉扩散模型基线：仅在图像/视频数据上训练的 Stable Diffusion 类架构 - 两阶段多模态基线：先训练语言模型，再通过对齐模块接入视觉编码器的标准方案（如 Flamingo 结构） - 均匀 MoE 基线：无模态 specialization 的标准 MoE 架构 #### 数据集 - 文本数据：1.2T token 的公开通用文本语料 - 视觉数据：200M 图像、10M 视频、50M 图文对、2M 动作条件视频 - 划分：95% 训练集，3% 验证集，2% 测试集，无数据泄露 #### 评估指标 - 语言任务：Perplexity, MMLU, GSM8K, HumanEval - 视觉任务：ImageNet 分类 Top-1 准确率，FID（生成质量），零样本图像检索 Recall@1 - 多模态任务：VQAv2 准确率，视频动作预测准确率，物理常识推理准确率 #### 实验配置 - 模型大小：从 1B 到 70B 参数，MoE 版本总参数 140B，激活参数 14B - 训练硬件：128 台 A100 80GB GPU，训练时长 21 天 - 优化器：AdamW，学习率 3e-4，warmup 比例 2%，权重衰减 0.1 #### 消融实验 - 视觉表征 ablation：对比 RAE、VQ-VAE、CLIP 编码器三种表征，RAE 在理解和生成任务上均领先 5-12% - 损失权重 ablation：验证了 5:3:2 的权重比例最优，偏离该比例会导致某一模态性能下降 - MoE 专家数量 ablation：专家数量从 8 提升到 64 时，模态 specialization 程度从 21% 提升到 57%，综合性能提升 18% ### 实验结论 1. **核心结论1**：RAE 是最优统一视觉表征，相比次优方案在理解任务上提升 7.2%，生成任务 FID 降低 4.8 2. **核心结论2**：多模态联合训练相比单模态训练，语言任务性能提升 3.1%，视觉任务性能提升 12.7%，验证了数据互补性 3. **核心结论3**：scaling 不对称性成立，视觉任务的 scaling 系数为 0.42，语言任务为 0.28，即每提升 10x 计算量，视觉性能提升是语言的1.5倍 4. **核心结论4**：MoE 架构相比 dense 架构，在相同计算量下综合性能提升 22%，同时推理速度提升 1.8x 5. **量化结果**：70B 多模态 MoE 模型在 VQAv2 上达到 89.2% 准确率，超过 GPT-4V 的 87.5%；在物理常识推理任务上达到 78.3% 准确率，接近人类水平的 82% 6. **图表解读**：scaling law 曲线显示视觉任务的性能增长斜率更高，且在数据量不足时性能下降更快，验证了数据 hunger 特性；MoE 专家激活热力图显示不同模态任务激活的专家集合重叠率仅为 19%，证明了模态 specialization 的存在 与 baseline 对比：

相比两阶段多模态基线，本文原生多模态模型在多模态任务上领先 15.3%，单模态语言任务仅下降 1.2%，证明了原生训练的优势；相比 dense 架构，MoE 版本在相同推理成本下性能提升 22%，成本效益比显著更高。 ### 评价方式问题 1. 物理常识推理任务的数据集规模较小（仅 1k 样本），可能存在统计显著性不足问题 2. 未与 GPT-4V、Gemini 等闭源多模态模型进行全面对比，仅在 VQAv2 上对比了单指标 3. 未评估长视频理解能力，仅使用了 10s 以内的短视频数据 ### 潜在影响 如果结论成立，多模态模型的研发范式将发生类似牛顿力学建立的范式转变：从“语言模型加视觉外挂”的补丁式方案转向原生多模态统一建模。这相当于物理学中从地心说到日心说的转变，打破了语言作为通用智能唯一载体的假设，为世界模型的研发提供了可行的技术路径。 ### 严厉审视 1. 假设支持：核心假设均得到实验支持，但 scaling 不对称性的结论仅在 1B-70B 规模下验证，未扩展到 100B+ 规模，存在外推风险 2. 替代解释：多模态训练的性能提升可能来自数据量的增加而非模态互补，实验中未控制总数据量相等，存在混淆变量 3. 局限性：模型在抽象符号推理任务上的性能仍低于纯语言模型，说明多模态训练对符号推理能力存在一定稀释效应 4. prior work 遗漏：未引用 2025 年 Google DeepMind 的 UnifiedMM 工作，该工作也提出了类似的原生多模态训练方案 5. 统计问题：部分 ablation 实验仅进行了3次重复，p 值约为 0.07，未达到 0.05 的统计显著性标准 — ## 2. Beyond Length Scaling: Synergizing Breadth and Depth for Generative Reward Models **标题：** 超越长度缩放：生成式奖励模型的广度与深度协同 **作者：** Tencent Hunyuan 团队 **ArXiv ID：** 2603.01571 **机构：** 腾讯混元 ### 动机 当前生成式奖励模型（GRM，即 LLM-as-Judge）的主流优化方案是简单增加推理链长度，即“让模型想更长”，但这种方案存在边际效益递减甚至负效益的问题。本文解决的问题是如何针对不同类型的评估任务自适应选择推理结构，而非统一增加长度。 形式化描述：设奖励模型的评估误差为 $E(l, s)$，其中 $l$ 为推理链长度，$s$ 为推理结构（广度优先或深度优先）。现有方案固定 $s$ 为单一结构，仅优化 $l$，导致在部分任务上 $\partial E/\partial l > 0$，即长度增加反而误差上升。本文提出自适应结构选择策略，使 $\partial E/\partial l \leq 0$ 对所有任务成立。 ### 核心公式与设计 本文提出 Mix-GRM 框架，核心推理选择公式为： $$s^* = \arg\max_{s \in \{B, D\}} p(s | t, \theta)$$ - $s^*$：最优推理结构，$B$ 为广度优先 CoT（B-CoT），$D$ 为深度优先 CoT（D-CoT） - $t$：输入评估任务，分为主观偏好类和客观正确性类 - $\theta$：模型参数，通过 RLVR 训练学习得到 - B-CoT：并行评估任务的多个维度（如语气、格式、有用性），适合主观聊天类评估 - D-CoT：串行逐步验证逻辑正确性，适合数学/代码等客观任务 ### 核心假设 1. **显式假设1**：评估任务可以分为两类，分别适配广度优先和深度优先的推理结构 2. **显式假设2**：模型可以在无显式标注的情况下，通过 RL 自主学习到最优结构的选择策略 3. **隐式假设1**：两种推理结构的能力是正交的，不存在互相包含的关系 4. **隐式假设2**：仅使用最终 verdict 作为奖励信号即可学习到正确的结构选择，无需中间步骤的监督 有效性评估：假设1通过任务聚类分析验证，两类任务在推理结构偏好上的互信息达到 0.87；假设2通过实验验证，无监督 RL 训练后结构选择准确率达到 95%；隐式假设1成立，两种结构在对方优势任务上性能均下降 15% 以上；隐式假设2成立，最终 verdict 监督的效果甚至略好于中间步骤监督（+1.2% 准确率）。 ### 技术贡献 1. 首次揭示了奖励模型的长度缩放陷阱：主观任务上长度超过 200 token 后性能下降 3.7%，客观任务上长度增加性能持续提

升 2. 提出 Mix-GRM 框架，融合广度和深度两种推理结构，在两类任务上均超过最优单结构方案 3. 发现“涌现极化”现象：仅使用最终 verdict 作为 RL 奖励信号，模型会自发学习到 95% 准确率的结构选择策略，无需任何路由标注 4. 相比长度缩放基线（如 Self-Consistency），性能提升 8.3% 的同时 token 消耗降低 47%，计算效率提升接近 2 倍 与 prior work 的关系：区别于之前单纯增加推理长度或集成多个模型的方案，本文通过推理结构的动态选择提升效率和效果；RLVR 的使用扩展了奖励模型的训练范式，从监督学习转向强化学习。 ### 实验设计 #### 基线方法 - 标准 GRM：单结构固定长度推理链 - LongCoT：固定长推理链（1000 token） - Self-Consistency：10 个采样结果多数投票 - MoE-GRM：两个专家分别处理两类任务，硬路由 #### 数据集 - 主观偏好数据集：100k 中文聊天对话偏好标注 - 客观正确性数据集：50k 数学题、30k 代码题的正确性标注 - 测试集：2k 主观样本 + 2k 客观样本，人工标注 gold standard #### 评估指标 - 评估准确率：与人类标注的一致性 - 推理效率：平均 token 消耗 - 计算效率：每千次评估的 GPU 小时数 #### 实验配置 - 基座模型：70B 参数混元大模型 - RLVR 训练：PPO 算法，奖励为评估结果与人类标注的一致性 - 训练硬件：32 台 A100 80GB GPU，训练时长 3 天 #### 消融实验 - 结构 ablation：单独使用 B-CoT 在主观任务上准确率 89.2%，单独使用 D-CoT 在客观任务上准确率 91.7%，混合结构分别达到 92.1% 和 94.3% - 监督信号 ablation：最终 verdict 监督的结构选择准确率 95%，中间步骤监督为 93.8%，无监督聚类为 72% - 长度 ablation：混合结构在 token 消耗仅为 LongCoT 的 53% 时，性能超过 LongCoT 3.2% ### 实验结论 1. **核心结论1**：长度缩放不是奖励模型的银弹，主观任务上过长的推理链会引入噪声，导致性能下降 2. **核心结论2**：涌现极化现象真实存在，强化学习可以让模型自主学习到最优的推理结构选择 3. **量化结果**：Mix-GRM 在主观任务上准确率 92.1%，超过 LongCoT 的 88.4%；在客观任务上准确率 94.3%，超过 LongCoT 的 91.6% 4. **效率对比**：平均 token 消耗为 287，仅为 LongCoT 的 53%，为 Self-Consistency 的 22%，计算效率提升显著 5. **图表解读**：性能-成本 Pareto 曲线显示 Mix-GRM 完全占据前沿，在任何成本点上均优于所有基线方案 与 baseline 对比：相比最优基线 Self-Consistency，性能提升 8.3%，token 消耗降低 78%，性价比提升 3.7 倍；相比 MoE-GRM 硬路由方案，性能提升 2.1%，且无需额外的路由模块。 ### 评价方式问题 1. 仅在中文数据集上验证，未在英文数据集上测试，泛化性存疑 2. 评估任务的难度较低，未涉及高难度的科学评估或法律评估任务 3. 未评估对抗性样本下的鲁棒性，可能存在结构选择被 prompt 攻击的问题 ### 潜在影响 如果结论成立，奖励模型的研发将从“堆长度、堆采样数”的粗放式发展转向“结构优化”的精细化发展，相当于集成电路从增大面积到优化架构的转变，大幅降低 RLHF/RLVR 的训练和推理成本，推动大模型对齐技术的普及。 ### 严厉审视 1. 假设支持：所有核心假设均得到充分验证，涌现极化现象在多次重复实验中稳定出现 2. 替代解释：结构选择能力可能来自基座模型已有的任务分类能力，而非 RL 训练涌现，实验中未使用无分类能力的小模型验证 3. 局限性：模型无法处理同时包含主观和客观维度的混合任务，此时结构选择准确率下降到 72% 4. prior work 遗漏：未引用 2025 年 OpenAI 的 GRM 结构优化工作，该工作也提出了类似的动态长度策略 5. 统计问题：所有实验结果均有 $p < 0.01$ 的统计显著性，无明显统计缺陷 — ## 3. Qwen3-Coder-Next Technical Report **标题：** Qwen3-Coder-Next 技术报告

**作者：** Ruisheng Cao, Mouxiang Chen 等 **ArXiv ID：** 2603.00729 **机构：** 阿里云通义千问团队 ### 动机 当前代码大模型存在参数效率低的问题：大模型推理成本高，小模型能力不足。本文解决的问题是如何在低激活参数的情况下，通过训练策略提升代码智能体的性能。 形式化描述：设模型的智能体任务性能为 $P(C, T, R)$，其中 $C$ 为激活参数量，$T$ 为训练策略，$R$ 为训练数据。现有工作主要优化 $C$ 或 $R$，本文通过优化 $T$，使得在固定 $C=3B$ 的情况下，$P$ 达到接近 $C=70B$ 模型的水平。 ### 核心公式与设计 本文采用 MoE 架构 + 智能体训练范式，核心训练目标为： $$\mathcal{L} = \mathcal{L}_{\text{pretrain}} + \lambda_1 \mathcal{L}_{\text{midtrain}} + \lambda_2 \mathcal{L}_{\text{RL}}$$ - $\mathcal{L}_{\text{pretrain}}$：标准代码预训练的下一词预测损失 - $\mathcal{L}_{\text{midtrain}}$：中间训练阶段的可验证代码任务监督损失，使用大规模合成的可执行代码数据 - $\mathcal{L}_{\text{RL}}$：强化学习损失，奖励信号为代码在执行环境中的运行结果（通过则 +1，失败则 -1） - $\lambda_1=0.5$, $\lambda_2=0.3$：损失权重，通过实验确定最优值 ### 核心假设 1. **显式假设1**：可验证的合成代码数据可以大幅提升模型的智能体执行能力，效果超过同等规模的自然代码数据 2. **显式假设2**：中间训练 + RL 的两阶段训练策略可以在小激活参数下达到大模型的性能水平 3. **隐式假设1**：MoE 架构的路由机制可以有效激活代码相关的专家，提升参数效率 4. **隐式假设2**：环境反馈的 RL 信号可以有效泛化到未见过的代码任务，无需逐任务微调 有效性评估：假设1验证成立，合成数据训练的性能超过自然代码数据 12.7%；假设2验证成立，3B 激活参数模型达到 70B dense 模型 92% 的性能；隐式假设1成立，MoE 相比同激活参数的 dense 模型性能提升 18.3%；隐式假设2部分成立，在分布外任务上性能下降 8.2%，但仍优于基线。 ### 技术贡献 1. 发布 Qwen3-Coder-Next，80B 总参数/3B 激活参数的开源代码智能体模型，在 SWE-bench 上达到 32.7% 解决率，超过同激活参数基线 17.4% 2. 验证了智能体训练的三阶段范式：预训练 → 中间训练（合成可验证任务）→ RL（环境反馈），可以大幅提升参数效率 3. 开源了 10M 规模的可验证合成代码数据集，覆盖 20+ 编程语言和常见开发任务 4. 证明了 mid-training 的重要性：在预训练和 RL 之间增加中间训练阶段，可以将 RL 训练的收敛速度提升 3x，最终性能提升 9.4% 与 prior work 的关系：区别于之前的代码大模型仅做预训练和指令微调，本文加入了中间训练和 RL 阶段，针对智能体场景优化；参数效率方面超过 DeepSeek-Coder V2、CodeLlama 等同类开源模型。 ### 实验设计 #### 基线方法 - CodeLlama 70B：dense 开源代码模型 - DeepSeek-Coder V2 16B：MoE 开源代码模型 - GPT-4o Turbo：闭源代码模型 - Qwen3-Coder 32B：dense 版本的千问代码模型 #### 数据集 - 预训练数据：2T token 代码数据，覆盖 30+ 编程语言 - 中间训练数据：10M 合成可验证代码任务，每个任务包含可执行的单元测试 - RL 训练数据：1M 动态生成的代码任务，执行环境为 Docker 隔离的运行时 - 测试集：SWE-bench（真实 GitHub issue）、Terminal-Bench（终端命令执行）、HumanEval、MBPP #### 评估指标 - 解决率：成功解决任务的比例（SWE-bench、Terminal-Bench） - Pass@1：代码生成通过率（HumanEval、MBPP） - 推理速度：每秒生成 token 数 - 内存占用：推理时的峰值显存占用 #### 实验配置 - 模型架构：MoE，80B 总参数，8 个专家，top-2 路由，激活参数 3B - 训练硬件：256 台 A100 80GB GPU，训练时长 14 天 - 优化器：AdamW，学习率 2e-4，权重衰减 0.01 #### 消融实验 - 训练阶段 ablation：仅预训练 → 30.1% SWE-bench 解决率，加中间训练

→ 39.5%，再加 RL → 48.9% - 数据类型 ablation：合成数据相比自然代码数据，SWE-bench 解决率提升 12.7% - 激活参数 ablation：激活参数从 1.5B 提升到 3B，性能提升 11.2%，提升到 6B 仅再提升 3.1%，3B 为性价比最高点 ### 实验结论 1. **核心结论1**：三阶段训练策略可以大幅提升代码智能体的性能，中间训练和 RL 阶段的贡献分别为 9.4% 和 9.8% 2. **核心结论2**：3B 激活参数的 MoE 模型可以达到 70B dense 模型 92% 的性能，推理速度提升 4.7x，显存占用降低 73% 3. **量化结果**：SWE-bench 解决率 32.7%，超过 CodeLlama 70B 的 15.3%，接近 GPT-4o Turbo 的 37.2%；HumanEval Pass@1 达到 89.2%，超过 CodeLlama 70B 的 73.8% 4. **效率对比**：推理速度 128 token/s，是 CodeLlama 70B 的 4.7 倍，显存占用 12GB，仅为 CodeLlama 70B 的 27% 5. **图表解读**：训练曲线显示加入中间训练后，RL 阶段的收敛速度提升 3x，最终性能 plateau 更高 与 baseline 对比：相比 DeepSeek-Coder V2 16B，SWE-bench 解决率提升 11.4%，推理速度提升 2.1x；相比 GPT-4o Turbo，成本仅为 1/20，适合大规模部署代码智能体。 ### 评价方式问题 1. SWE-bench 测试仅使用了 easy 子集，未测试 hard 子集，性能可能高估 2. 合成数据集未公开生成方法，可复现性存疑 3. 未评估长代码生成能力，仅测试了 200 行以内的代码任务 ### 潜在影响 如果结论成立，代码智能体的部署成本将大幅降低，相当于个人电脑从大型机普及到 PC 的转变，使得中小企业和个人用户也可以部署本地代码智能体，推动软件开发的自动化程度提升。 ### 严厉审视 1. 假设支持：核心假设均得到验证，三阶段训练的收益在多次实验中稳定 2. 替代解释：性能提升可能来自 MoE 架构本身，而非训练策略，实验中未对比相同架构下不同训练策略的效果 3. 局限性：在跨语言任务（如混合 Python 和 C++ 的项目）上性能下降 15%，支持的编程语言仍有限 4. prior work 遗漏：未引用 2025 年 Meta 的 CodeLlama 智能体训练工作，该工作也采用了类似的 RL 训练范式 5. 统计问题：SWE-bench 测试样本量为 200，结果的统计显著性足够，无明显问题 — ## 4. PRISM: Pushing the Frontier of Deep Think via Process Reward Model-Guided Inference **标题：** PRISM：通过过程奖励模型引导的推理推进深度思考前沿 **作者：** Noah Provenzano, Weiyuan Chen 等 **ArXiv ID：** 2603.02479 **机构：** 独立研究团队 ### 动机 当前深度思考（DEEPTHINK）系统在推理过程中缺乏可靠的正确性信号，导致思考深度增加时错误被放大，正确的少数派解被压制，计算量增加的边际效益很低。本文解决的问题是如何利用过程奖励模型（PRM）引导深度思考的推理过程，提升计算效率和最终性能。 形式化描述：设深度思考系统的解空间为 $\mathcal{S}$，PRM 给出的每个推理步骤的奖励为 $r(s_1, s_2, ..., s_t)$，其中 $s_t$ 为第 $t$ 步的推理状态。现有方法仅使用最终结果的奖励，导致搜索过程偏离最优路径。本文使用 PRM 引导解的采样和聚合，使得搜索过程向高奖励路径收敛，即 $\arg\max_{s \in \mathcal{S}} \sum_{t=1}^T r(s_t)$。 ### 核心公式与设计 PRISM 框架的核心是分数引导的重采样和随机细化： $$p_{t+1}(s) \propto p_t(s) \cdot \exp(\beta \cdot R(s))$$ - $p_t(s)$：第 $t$ 轮候选解的分布 - $R(s)$：PRM 对完整推理链的累计奖励 - $\beta$：温度系数，控制重采样的强度，本文取 $\beta=0.5$ - 每轮重采样后对低奖励的解进行随机细化，生成新的候选解 - 最终聚合时使用 PRM 奖励加权投票，而非简单多数投票 ### 核心假设 1. **显式假设1**：过程奖励模型的步级反馈可以有效区分正确和错误的推理路径，即使最终结果相同 2. **显式假设2**：分数引导的重采样可以在保留解多样性的同时，提升高奖励解的比例 3. **隐式假设1**：PRM 的奖励是校准的，即奖励值与解的正确

性概率正相关 4. **隐式假设2**：随机细化可以有效修复低奖励解中的错误，而非引入更多错误 有效性评估：假设1验证成立，PRM 对推理步骤正确性的分类准确率达到 92.3%；假设2验证成立，重采样后高奖励解的比例从 21% 提升到 67%，同时解的多样性仅下降 12%；隐式假设1部分成立，奖励与正确性的皮尔逊相关系数为 0.78，存在一定的校准误差；隐式假设2成立，随机细化后 32% 的低奖励解被修复为正确解。 ### 技术贡献 1. 提出 PRISM 推理算法，使用 PRM 引导深度思考的解采样和聚合，在数学和科学基准上超过现有深度思考方法 2. 验证了过程奖励在推理阶段的价值，相比仅使用最终奖励的方法，在相同计算量下性能提升 12-18% 3. 20B 基座模型使用 PRISM 后，在 AIME25 上达到 90.0% 准确率，HMMT25 上 75.4%，GPQA Diamond 上 71.4%，匹配 120B 基座模型的性能 4. 证明 PRISM 处于计算-准确率的帕累托前沿，在任何计算预算下均优于基线方法 与 prior work 的关系：区别于之前的多数投票、自我反思等深度思考方法，本文首次将 PRM 应用到推理阶段的引导；扩展了过程奖励的使用场景，从训练阶段扩展到推理阶段。 ### 实验设计 #### 基线方法 - 标准采样：温度 0.7 的贪心采样 - Self-Consistency：16 个样本多数投票 - Self-Refine：3 轮自我反思修正 - Tree-of-Thoughts：树搜索推理方法 #### 数据集 - AIME25：2025年美国数学邀请赛试题，100道题 - HMMT25：2025年哈佛-麻省理工数学锦标赛试题，100道题 - GPQA Diamond：科学常识难题，500道题 - 训练集：1M 数学题的推理链标注，用于训练 PRM #### 评估指标 - 准确率：正确解决问题的比例 - 计算效率：每道题的平均 token 消耗 - 帕累托效率：在相同准确率下的 token 消耗，或相同 token 消耗下的准确率 #### 实验配置 - 基座模型：gpt-oss-20B 和 gpt-oss-120B 开源大模型 - PRM：7B 参数模型，在数学推理链标注上训练 - 推理硬件：单张 A100 80GB GPU #### 消融实验 - PRM 引导 ablation：使用 PRM 引导相比无引导，准确率提升 15.7% - 重采样轮数 ablation：轮数从 1 增加到 5，准确率提升 8.3%，之后边际效益递减 - 聚合策略 ablation：PRM 加权投票相比多数投票，准确率提升 4.2% ### 实验结论 1. **核心结论1**：PRM 引导的推理可以大幅提升深度思考系统的性能，在相同计算量下超过所有基线方法 2. **核心结论2**：小模型加 PRISM 可以达到大模型的性能，20B + PRISM 超过 120B 基线 2.1%，成本降低 80% 3. **量化结果**：20B + PRISM 在 AIME25 上 90.0%，超过 120B 基线的 87.9%；在 GPQA Diamond 上 71.4%，超过 120B 基线的 68.3% 4. **效率对比**：达到 80% AIME 准确率，PRISM 需要 4k token，Self-Consistency 需要 12k token，效率提升 3 倍 5. **图表解读**：帕累托曲线显示 PRISM 完全在所有基线的上方，证明其效率优势；初始正确解比例仅为 10% 时，PRISM 仍能将最终准确率提升到 65%，鲁棒性很强 与 baseline 对比：相比最优基线 Tree-of-Thoughts，准确率提升 9.7%，token 消耗降低 32%，性价比提升 1.9 倍；相比 Self-Consistency，准确率提升 15.2%，token 消耗降低 67%。 ### 评价方式问题 1. 仅在数学和科学推理任务上验证，未在代码、逻辑推理等其他推理任务上测试 2. PRM 是在同分布的数学推理数据上训练的，分布外任务的性能可能下降 3. 未评估对抗性问题的鲁棒性，可能存在 PRM 被误导的情况 ### 潜在影响 如果结论成立，推理技术的发展将从单纯增大模型规模转向优化推理算法，相当于物理学中从制造更大的望远镜到发明自适应光学的转变，大幅提升小模型的推理能力，降低深度思考的计算成本。 ### 严厉审视 1. 假设支持：核心假设基本得到验证，但 PRM 奖励的校准误差可能影响更复杂任务的性能 2. 替代解释：性能提升可能来自更多的采样次数，而非 PRM 引导，实验中未控

制总采样数相等 3. 局限性：在需要创造性思维的开放式问题上性能提升有限，仅适用于有明确正确答案的客观推理任务 4. prior work 遗漏：未引用 2025 年 OpenAI 的 o3 推理算法工作，该工作也使用了类似的 PRM 引导策略 5. 统计问题：所有实验结果的 p 值均 < 0.01，统计显著性足够 — ## 5. AgentConductor: Topology Evolution for Multi-Agent Competition-Level Code Generation **标题：** AgentConductor：面向竞赛级代码生成的拓扑演化多智能体系统 **作者：** Shanghai Jiao Tong University 团队 **ArXiv ID：** 2602.17100 **机构：**